Prévia Dissertação

Detecção de Crises Epilépticas com sinais de EEG - Revisão Bibliográfica

Submetido à Comissão Coordenadora do Programa de Pós-Graduação em Engenharia Elétrica

Orientando: Guilherme Reis da Silva
Orientador: Daniel Gilio Tiglea
Coorientador: Magno Teófilo Madeira da Silva

Resumo

Dezenas de milhões de pessoas no mundo sofrem com doenças e distúrbios neurológicos, como por exemplo doença de Alzheimer, Parkinson e Epilepsia. O acompanhamento e tratamento dos pacientes com esses distúrbios muitas vezes utiliza como principal ferramenta os exames de eletroencefalograma (EEG). O EEG é capaz de transcrever as atividades elétricas do cérebro em uma série temporal de dados que virá a ser analisada por profissionais da área em questão.

A epilepsia é objeto de estudo de diversos profissionais da área de engenharia biomédica por conta da sua natureza elétrica. Médicos e especialistas conseguem distinguir sinais de EEG de momentos de crises epilépticas de sinais de EEG que não representam crises; além de catalogar o tipo de crise em questão. Partindo da premissa de que a análise visual realizada por especialistas permite a identificação e classificação dessas crises, a literatura propõe que algoritmos de aprendizado de máquina podem ser treinados para extrair padrões semelhantes de forma automatizada.

Neste projeto de pesquisa foi proposto uma revisão bibliográfica, com estudo, replica e potencial aprimoramento de alguns algoritmos propostos pela literatura focados em detecção de crises (ou classificação entre um sinal que representa o cérebro no estados com e sem crise epiléptica).

Para atingir tal objetivo foi utilizado o banco de dados público CHB-MIT Scalp Database [colocar na referencia], com sinais já rotulados por profissionais da área neurológica. Os algoritmos de aprendizado de máquina foram implementados com a biblioteca PyTorch [colocar na referencia] implementada em Python. O computador usado nos treinamentos era um [colocar as especificações da Lecun].

Foi necessário estudar teoria do Caos pois parte da literatura utiliza a interpretação do cérebro como um sistema dinâmico caótico para extrair características que são usadas para alimentar os algoritmos de detecção.

[No fim do resumo colocar alguns resultados numéricos obtidos das réplicas q eu fiz? Não sei se é pertinente pois eu estou apenas tentando replicar, e não construindo algo novo ainda]

Palavras-Chave – Detecção de Crises Epiléticas, Aprendizado de Máquina, Serial Vector Machine (SVM), Teoria do Caos.

1 Introdução

A epilepsia é uma doença neurológica crônica que causa atividades elétricas anormais e inesperadas no cérebro. Essas atividades elétricas recebem o nome de "Crise Epiléptica" e podem variar desde pequenos espasmos até perda de consciência [1]. Dados da Organização Mundial da Saúde (OMS) de 2024 estimam que 50 milhões de pessoas no mundo são afetadas por essa doença (7 a cada 1000 pessoas) [2], e dentre elas, cerca de 30% dos casos são resistentes à medicação para controlar tais crises [3]. A epilepsia resistente à medicamentos está associada a riscos elevados, como acidentes, efeitos colaterais psicológicos, cognitivos e à morte súbita, chamada de *Sudden Unexpected Death in Epilepsy* (SUDEP) [4].

Por conta da natureza elétrica das crises epilépticas, a principal ferramenta utilizada para análise, caracterização e diagnóstico da epilepsia é o Eletroencefalograma (EEG). O EEG é um exame que registra a atividade elétrica do cérebro meio de eletrodos, fornecendo informações sobre o funcionamento desse órgão. O exame de EEG pode ser invasivo; em que eletrodos intracranianos são inseridos por um neurocirurgião em um paciente anestesiado; ou não invasivo; em que são colocados eletrodos na cabeça, na superfície do couro cabeludo [5]. Utilizando sinais de EEG, profissionais especializados podem identificar padrões anormais de atividade cerebral, localizar o foco das crises e classificar as síndromes epilépticas. Apesar do EEG de couro cabeludo ser amplamente utilizado por ser não invasivo, ele apresenta limitações de resolução, o que pode exigir o uso de EEG invasivo, especialmente em avaliações pré-cirúrgicas e/ou com epilepsia refratária a medicamentos [colocar nas referencias]https://www.epilepsy.com/diagnosis/eeg.

A digitalização dos registros de EEG impulsionou a criação de bancos de dados, tanto públicos quanto privados. Como exemplo de banco de dados público há o CHB-MIT Scalp EEG Database [6], desenvolvido a partir de um estudo conjunto entre o *Children's Hospital Boston* e o *Massachusetts Institute of Technology* (MIT) [7]. Como exemplo de banco de dados privado há o EPILEPSIAE [8] desenvolvido pelo *Seizure Prediction Project* da Universidade de Freiburg [9]. A disponibilidade desses dados favorece o desenvolvimento de técnicas computacionais voltadas à detecção, classificação e previsão de crises epilépticas. A relevância e atualidade desses temas na literatura ficam evidentes pela presença de trabalhos submetidos a congressos de processamento de sinais, tanto nacionais, como o Congresso Brasileiro de Engenharia Biomédica (CBEB) [10][11], quanto internacionais, como o *European Signal Processing Conference* (EUSIPCO) [12], *International Conference on Acoustics, Speech, and Signal Processing* (ICASSP) [13] e o *Engineering in Medicine and Biology Conference* (EMBC) [14]. O engajamento da comunidade científica também se mostra na promoção de iniciativas como o "Una Europa Epilepsy Data Challenge" [15], um desafio internacional criado em 2025 para fomentar o aprimoramento de algoritmos na detecção de crises utilizando uma base de dados preparado para dispositivos vestíveis (*wearables*) [16].

Atualmente diversos modelos de detecção de crises epilépticas têm alcançado resultados considerados satisfatórios para classificar sinais que representam crises e separá-los dos sinais sem crise. Mesmo assim há desafios significativos em aberto. Alguns desafios da detecção de crises epilépticas são:

- Variabilidade do Paciente: Algoritmos treinados com dados de um paciente ou conjunto de dados específico costumam apresentar desempenho menos satisfatório condições diferentes às de treino. Isso é devido à significativa variabilidade do sinal de EEG entre pacientes. Generalizar modelos para diferentes tipos de crises, populações demográficas e configurações de gravação é um grande desafio.

- Escassez e Qualidade dos Dados: Dados de EEG anotados de alta qualidade e longo prazo são escassos devido a regulamentações de privacidade, altos custos de rotulagem e inconsistências na anotação de especialistas. A maioria dos conjuntos de dados públicos é pequena ou carece de diversidade de tipos de crises, o que pode levar ao *overfitting* e a métricas de desempenho infladas.

- Restrições computacionais em tempo real: Alguns algoritmos são complexos de tal forma que exigem recursos computacionais que dificultam sua incorporação em *wearables* para monitoramento ambulatorial de longo prazo e em tempo real.

Na literatura há diversas abordagens para a detecção automática de crises de epilepsia utilizando sinais de EEG. Os resultados de cada abordagem variam conforme o domínio de extração de características do sinal e o classificador escolhido. A partir de dados do artigo de revisão "Automated Epileptic Seizure Detection in Pediatric Subjects of CHB-MIT EEG Database—A Survey" [17], um trabalho que compila informações sobre estudos de detecção de crises epilépticas, foi feito um levantamento que relaciona alguns algoritmos com os resultados em detecção de crises. Os resultados de alguns algoritmos podem ser visto na tabela 1.

[mudar essa tabela para colocar explicitamente resultados de algoritmos que usam teoria do caos]

Tabela 1: Comparação de Algoritmos para Detecção de Crises Epilépticas

Domínio de Extração	**Método / Estudo**	**Características Extraídas**	**Classificador**	**Desempenho Reportado**
Domínio do Tempo	PCA [18]	Quantile, Inter Quantile, Range, Shannon entropy, Root-Mean-Square, Coefficient of Variation, Energy	LDA e NB	Sensitivity: 88,27% Specificity: 93,21%
Domínio da Frequência	Filter bank [19]	Temporal variability information	SVM	Sensitivity: 100%
Domínio de Tempo-Frequência	EMD [20]	Mean of coefficients, average power of coefficient in every sub-band, std-deviation of coefficients, skewness e kurtosis	SVM, RF, MLP e K-NN	Accuracy: 99,7% Sensitivity: 99,65% Specificity: 99,8%
Domínio Não-Linear	RQA [21]	Determinism, Avg-diagonal line length, entropy, laminarity e trapping time	ECOC	Sensitivity: 97,4% Specificity: 93,5%

Não há consenso na literatura sobre quais devem ser as métricas de qualidade de um algoritmo de detecção de crises epiléticas. Mas as principais são:

Acurácia (Accuracy)

Representa a proporção de classificações corretas em relação ao total de amostras. Essa é uma medida quantitativa do desempenho do algoritmo em detectar uma crise que realmente aconteceu (verdadeiro positivo) e de não detectar uma crise em um sinal realmente saudável (verdadeiro negativo).

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \times 100 \tag{1}$$

Sensibilidade (Sensitivity)

Mede a capacidade do sistema de detectar corretamente os eventos de crise epiléptica (verdadeiros positivos); a capacidade de não deixar uma anomalia passar desapercebida.

$$\text{Sensitivity} = \frac{TP}{TP + FN} \times 100 \tag{2}$$

Especificidade (Specificity)

Mede a capacidade do sistema de detectar corretamente os eventos que não são crises (verdadeiros negativos). Parâmetro quantitativo da capacidade do sistema de reconhecer um comportamento normal e não criar pânico a toa.

$$\text{Specificity} = \frac{TN}{TN + FP} \times 100 \tag{3}$$

Uma falha comum em sistemas de detecção de anomalias é o detector acusar que toda janela de análise é uma anomalia. Isso leva a casos em que a sensibilidade vai para 100% porém a especificidade cai para 0%.

Valor Preditivo Positivo (Precision)

Indica a proporção de eventos identificados como crise que realmente eram crises epilépticas. Essa métrica responde a pergunta "Se o sistema disse que tal momento é uma crise, o quão confiável é essa afirmação?".

$$\text{Positive Predictive Value} = \frac{TP}{TP + FP} \times 100 \tag{4}$$

PCA = *Principal Component Analysis* ou Análise de Componentes Principais: Técnica estatística usada para reduzir a dimensionalidade dos dados (extraindo as características mais relevantes) preservando a maior parte da variância do sinal.
SVM = *Support Vector Machine* ou Máquina de Vetores de Suporte: Classificador supervisionado que busca encontrar a linha ou hiperplano ideal que melhor separa as diferentes classes de dados (ex: crise epiléptica vs. atividade normal).
NB = *Naïve Bayes* ou Bayes Ingênuo: Classificador probabilístico rápido e simples baseado no Teorema de Bayes e que assume que todas as características extraídas são independentes entre si.
EMD = *Empirical Mode Decomposition* ou Decomposição em Modos Empíricos: Método de processamento de sinais de tempo-frequência. Utiliza processamento adaptativo para decompor sinais não-lineares e não-estacionários em componentes mais simples chamadas de *Intrinsic Mode Functions* (IMF)
RF = *Random Forest* ou Floresta Aleatória: Algoritmo de classificação em conjunto (*ensemble*) que cria várias árvores de decisão durante o treinamento e combina seus resultados para aumentar a precisão e evitar o sobreajuste (*overfitting*).
MLP = *Multilayer Perceptron* ou Perceptron Multicamadas: Tipo clássico de rede neural artificial (*feedforward*) composta por pelo menos três camadas de nós (entrada, oculta e saída), capaz de classificar dados que não são linearmente separáveis.
K-NN = *K-Nearest Neighbors* ou K-Vizinhos Mais Próximos: Algoritmo de classificação que atribui uma classe a um dado não classificado com base na classe majoritária dos seus k vizinhos mais próximos no espaço de características.
RQA = *Recurrence Quantification Analysis* ou Análise de Quantificação de Recorrência: Método de análise não-linear usado para investigar o comportamento de sistemas dinâmicos no tempo, sendo útil para detectar transições de estado no cérebro.
ECOC = *Error-Correcting Output Code* ou Código de Saída Corretor de Erros: Técnica de meta-aprendizado que combina múltiplos classificadores binários simples para resolver problemas complexos de classificação com várias classes. TN = *True Negative* ou Verdadeiro Negativo
TP = *True Positive* ou Verdadeiro Positivo
FN = *False Negative* ou Falso Negativo
FP = *False Positive* ou Falso Positivo

Na revisão da literatura nota-se que cada estudo citado escolhe relatar as métricas que melhor validam seus resultados de pesquisa. Essa escolha está associada ao objetivo do estudo (por exemplo, criar um alarme rápido, criar um diagnóstico preciso) e não uma exigência inerente à matemática do classificador escolhido.

2 Abordagem Não-Linear - Teoria do Caos

O cérebro pode ser modelado como um sistema dinâmico não-linear que opera em pelo menos dois regimes: ictal e interictal. O termo "regime"é usado para que não usemos o termo "estado"e não causar confusão com nomenclaturas de sistemas dinâmicos. Em sistemas dinâmicos, um estado é um único ponto do espaço de fase do sistema, e o cérebro passa por milhões de estados dependendo dos estímulos e respostas de cada neurônio. O que muda numa crise epilética é o "atrator"ao qual a trajetória está confinada.

[Eu to na dúvida se explico antes o que é cada termo base/chave de teoria do caos para que essa introdução faça sentido ou se uso esse pequeno texto justamente como gatilho para explicar o que é cada coisa e por que isso tá aqui].

O exame de EEG atua como uma projeção de um sistema dinâmico de muitas dimensões. Cada eletrodo mede uma a atividade elétrica que é na verdade combinação/superposição da atividade de milhões de neurônios presentes na região da cabeça onde o eletrodo está conectado. A hipotese de diversos artigos e trabalhos da literatura é de que, durante uma crise epiléptica, o cérebro se torna um sistema com atividades mais cíclicas, previsíveis e "menos caóticas". [Explicar Lyapunov aqui?]

Um método muito utilizado na literatura para extrair caracteristicas não-lineares do cérebro a partir do sinal de EEG é a chamada "reconstrução do espaço de fase". Esse processo recria a "trajetória"em que o sistema dinâmico do cérebro muda de um estado para o outro. Se essa trajetória é previsível, o atrator é estável e o cérebro está no regime de crise epiléptica. Se a trajetória é caótica, o atrator é instável e o cérebro está no regime de atividade saudável.

Métodos estatísticos analisam o EEG como um sinal estpcástico e tentam observar mudanças e padrões na distribuição desses dados, assim como mudanças espectrais, conteúdo em frequencia, amplitude de bandas/faixas. Métodos não lineares, como o citado que utiliza reconstrução por espaço de fase, tenta verificar mudança nesse

próprio espaço reconstruído.

3 Teorias

3.1 Sistemas Dinâmicos Discretos

Um sistema dinâmico discreto é definido por um mapa (função) f e pela iteração v(k+1) = f(v(k)). Cada ponto dessa iteração é um estado do sistema. O primeiro ponto no processo iterativo é chamado de "ponto inicial"ou "condição inicial". A sequência de pontos e o "desenho"formado pela união de todos esses pontos/estados é o que chamamos de órbita. [Falar sobre pontos fixos] [Mostrar o coweb plot para explicar o processo iterativo de mapas]

Os conceitos de sistemas dinâmicos possuem paralelos e analogias com processamento digital de sinais. Um filtro IIR do tipo y[n] = a*y[n - 1] é também um mapa em R1. Esse filtro pode ser estável ou instável dependendo de "a". [comparar condição de estabilidade de um filtro com condição de estabilidade de órbita e pontos fixos em teoria do caos].

3.2 Reconstrução em Espaço de Fase - Teorema de Takens

A única grandeza medida e utilizada nos estudos deste projeto é a evolução dos sinais elétricos coletados por cada eletrodo. A variação da tensão ao longo do tempo representa apenas uma dimensão do sistema de ordem maior, que é o cérebro.

A dinâmica do cérebro é estimada utilizando o Teorema de Takens, que afirma que é possível reconstruir o espaço de fases de um sistema dinâmico a partir de uma única série temporal de observações [colocar referência pro teorema de takens].

[Acho que não preciso explicar aqui porque o Takens funciona, ou preciso? Tem referencias explicando toda a teoria por trás].

[Coloquei aqui uma descrição inicial pra não ficar vago demais esse espaço. Uma prova teórica mais robusta é necessário? É útil?].

Em um sistema determinístico as variáveis estão acopladas. A evolução histórica de uma variável medida carrega também informações sobre variáveis não medidas. Tomando como exemplo um pêndulo simples. O estado é composto pala tupla [posição, velocidade]. Se observarmos apenas a posição ao longo do tempo é possível recuperar a informação de velocidade do pendulo em um determinado instante, e assim, recuperar o estado inteiro.

$$\mathbf{v}(t) = [x(t), x(t+\tau), \ldots, x(t+(d-1)\tau)]$$

Neste trabalho o número de dimensões d = 5 e o tau = 6 amostras (aproximadamente 23ms a 256Hz de frequência de amostragem).

[Colocar em discussão a possibilidade de trocar esses parâmetros. A escolha deles hoje é devido o artigo que eu estou seguindo].

Importante: o teorema de Takens garante que o espaço de fases reconstruído é equivalente ao espaço original que seria gerado se tivéssemos acesso a todas as finitas dimensões que compõe o sistema. Não há como ter certeza absoluta que o cérebro se comporta sempre como um sistema dinâmico de dimensão finita. [Essa frase meio que resguarda o modelo como - Se não funcionar eh pq o cerebro nao é assim como a gente acha q ele é. Mas ao mesmo tempo isso tira confiança na hipótese: se não sabemos se é assim, pq assumir que é e tentar fazer funcionar?]

3.3 Seção de Poinceré

A seção de Poincaré é uma ferramenta usada em teoria do caos para estudar trajetórias de sistemas dinâmicos. A seção é um hiperplano transversal à órbita em estudo. Os pontos de intersecção entre o hiperplano e a órbita geram um desenho que pode fornecer informações sobre a natureza do da órbita.

Há quatro casos de desenhos formados pelos pontos de intersecção entre a Seção de Poincaré e a órbita do sistema em estudo:

3.4 Expoente de Lyapunov

O maior expoente de Lyapunov (do inglês Largest Lyapunov Exponent - LLE) é uma medida quantitativa de "o quanto um sinal é caótico ou não"e ele faz isso medindo a taxa de afastamento de trajetórias inicialmente próximas. Valores positivos de LLE indicam uma dinâmica caótica, típica de um EEG padrão. Valores negativos

Tabela 2: Relação entre o conjunto de interseções da Seção de Poincaré e o respectivo regime dinâmico do sistema.

Conjunto de interseções	**Regime indicado**
Um único ponto	Órbita periódica (ciclo limite)
k pontos	Órbita de período k
Curva fechada	Movimento quase-periódico (toro)
Nuvem difusa	Caos

estão associados ao fato de que a dinâmica do cérebro está mais regular e isso coincide com o ínicio da crise (essa é a hipótese base para usar caos ao analizar EEG).

[Colocar a expressão matemática do LLE]. [citar Rosenstein sobre como calcular computacionalmente o expoente de Lyapunov].

3.5 Análise de Componentes Principais (PCA)

O PCA é um método estatístico para reduzir dimensionalidade de um problema. [Eu acabei de ter um pensamento: Pq usar takens para aumentar a dimensão do EEG de $1 \gg 5$ e depois PCA de $5 \gg 2$? Pq não apenas usar Takens de $1 \gg 2$ e estudar o melhor d e tau pra isso?]. Reduzir dimensionalidade é bom para reduzir gastos computacionais excessivos e ajuda a evitar overfitting do modelo de aprendizado sob estudo.

O PCA transforma um conjunto de dados com muitas dimensões em um conjunto de dados com um número de dimensão menor. Cada dimensão desse espaço transformado é chamado de "componente principal". Essas novas dimensões são combinações lineares de cada dimensão original e o método tenta reter o máximo possível de informação dos dados originais.

[Colocar mais algumas infos aqui seguindo o documento que o Magno me mandou]

3.6 Máquina de Vetores de Suporte (SVM)

[https://scikit-learn.org/stable/modules/svm.html - Documentação do SciKit-Learn]. Esse link é útil pois eu uso ele pra entender como o scikit-learn implementou a SVM e uso de base para implementar com PyTorch. Esse link é bom pois tem imagens. Tentar replicar as imagens da documentação para mostrar como uma SVM funciona?

[`https://en.wikipedia.org/wiki/Support_vector_machine` - Explicação matemática de como implementar] [`https://www.geeksforgeeks.org/machine-learning/support-vector-machine-algorithm/`]

4 Banco de Dados

O banco de dados escolhido para desenvolver esse trabalho foi o CHB-MIT pois é um banco de dados público bastante utilizado na literatura. Os registros têm amostragem de 256Hz, resolução de 16 bits e eletrodos no sistema 10-20 de montagem bipolar, em que a leitura do sinal elétrico usa como referência outro eletrodo, e não uma referência única para todos os eletrodos. Por isso cada canal possui o nome em duas parte (ex.: FP1-F7); o primeiro nome é a região do eletrodo lido e o segundo é a referência. [Colocar foto da montagem 10-20] [Colocar foto de um sinal de EEG saudável e de um sinal com crise]

A maior parte dos arquivos tem 23 canais. [Voltar no documento da physionet e ver se o artigo atrelado ao banco de dados explica pq tem alguns arquivos que falta canal]. Entre arquivos consevutivos há lacunas de cerca de 10 segundos por conta de limitações de hardware durante a caputra dos dados de EEG [isso tá explícito no artigo]. Os intervalos de crise são extraídos dos arquivos ≪nome-do-canal¿-summary.txt"

A página do PhysioNet (onde o banco de dados está hospedado) e o artigo atrelado ao banco não cita a remoção de artefatos ou filtragem feita previamente à publicação do banco de dados. [Pegar lastro em artigos que usam esse banco de dados de que eles também não tratam de nenhuma forma os dados do banco]. [também não lembro de ter lido ninguem reclamar sobre a presença do 60Hz] Os autores explicitam que usaram trechos de pelo menos 24 horas de EEG sem crise por paciente para incluir trechos de sono e artefatos.

```
Data Sampling Rate: 256 Hz
************************

Channels in EDF Files:
**********************
Channel 1: FP1-F7
Channel 2: F7-T7
Channel 3: T7-P7
Channel 4: P7-O1
Channel 5: FP1-F3
Channel 6: F3-C3
Channel 7: C3-P3
Channel 8: P3-O1
Channel 9: FP2-F4
Channel 10: F4-C4
Channel 11: C4-P4
Channel 12: P4-O2
Channel 13: FP2-F8
Channel 14: F8-T8
Channel 15: T8-P8
Channel 16: P8-O2
Channel 17: FZ-CZ
Channel 18: CZ-PZ
Channel 19: P7-T7
Channel 20: T7-FT9
Channel 21: FT9-FT10
Channel 22: FT10-T8
Channel 23: T8-P8

File Name: chb01_01.edf
File Start Time: 11:42:54
File End Time: 12:42:54
Number of Seizures in File: 0
```

Figura 1: Estrutura do Banco de Dados CHB-MIT

```
File Name: chb01_26.edf
File Start Time: 12:34:22
File End Time: 13:13:07
Number of Seizures in File: 1
Seizure Start Time: 1862 seconds
Seizure End Time: 1963 seconds
```

Figura 2: Estrutura do Banco de Dados para o caso com crise

5 Como funcionam os scripts para Detecção de Crise (Pipeline)

O script `main_pipeline.py` é o gerenciador da sequência dos processos (conhecido popularmente como "pipeline") onde ocorre o processamento de sinais de eletroencefalograma (EEG) do *dataset* CHB-MIT. Ele executa em subprocessos independentes as três etapas subsequentes da cadeia de aprendizado de máquina:

1. **Parsing e Estruturação de Rótulos**: Leitura dos arquivos de sumário em texto do dataset
2. **Reconstrução do Espaço de Fase e Extração de Características**: Mapeamento em espaço de fase, projeção em Componentes Principais, Seção de Poincaré e extração de estatísticas
3. **Treinamento e Validação do Classificador**: Padronização, validação cruzada estratificada por paciente, busca por hiperparâmetros e otimização por Gradiente Descendente do SVM Primal

6 Etapa 1: Processamento do Dataset (`global_parse_dataset.py`)

6.1 Função `extrair_dados_sumario(caminho_arquivo)`

- **Motivo da Existência**: Os registros clínicos do CHB-MIT fornecem as anotações das crises epilépticas em formato de texto (`<nome-do-paciente>-summary.txt`). Esta função converte esse texto em uma estrutura de dados compatível com as funções do NumPy e CSV usadas pelas bibliotecas de aprendizado de máquina em Python.
- **Funcionamento**: Realiza um *parsing* identificando o nome de cada arquivo `.edf`, o número total de crises N, e os intervalos de tempo inicial e final (em segundos) de cada crise (label = 1). Arquivos sem crises registradas geram registros com label = 0.

7 Etapa 2: Reconstrução do Espaço de Fase e Características de Poincaré (`poincare_features.py`)

7.1 Função `time_delay_embedding(signal, d=5, tau=6)`

- **Motivo da Existência**: Conforme o Teorema de Reconstrução de Takens, o comportamento dinâmico não-linear do cérebro pode ser estimado a partir de uma única série temporal unidimensional $x(t)$ de EEG, projetando-a em um Espaço de Fase d-dimensional com tempo de atraso τ.
- **Formulação Matemática**: Dada uma janela temporal com N amostras $x = [x_1, x_2, \ldots, x_N]^T$ [eu lembro que o Vitor usava muito o "T"nas aulas pq era convenção o vetor ser vetor coluna], o vetor reconstruído no tempo i é dado por:

$$\mathbf{y}_i = \left[x_i, x_{i+\tau}, x_{i+2\tau}, \ldots, x_{i+(d-1)\tau}\right]^T \in \mathbb{R}^d \tag{5}$$

  O número total de pontos válidos na trajetória reconstruída é $N_v = N - (d-1)\tau$. A matriz do espaço de fase reconstruída é $\mathbf{Y} \in \mathbb{R}^{N_v \times d}$.

7.2 Funções `pca_transform(embedded, n_components=None)` e `fit_line(x, y)`

- **Motivo da Existência**: Para encontrar a Seção de Poincaré, o espaço de fase d-dimensional (ex: $d = 5$) é projetado no plano de maior variância espacial utilizando Análise de Componentes Principais (PCA) via Decomposição em Valores Singulares (SVD) [usar SVD para calcular PCA vem da documentação do scikit learn]. Em seguida, ajusta-se uma reta de corte de referência.
- **Formulação Matemática**: Centraliza-se a matriz $\mathbf{Y}$, isto é, removemos o valor médio de cada amostra do vetor e isso faz com que a distribuição dos dados seja centrada no zero:

$$\bar{\mathbf{Y}} = \mathbf{Y} - \mathbf{1}\boldsymbol{\mu}^T, \quad \boldsymbol{\mu} = \frac{1}{N_v}\sum_{i=1}^{N_v}\mathbf{y}_i \tag{6}$$

  A decomposição SVD de $\bar{\mathbf{Y}}$ é expressa por:

$$\bar{\mathbf{Y}} = \mathbf{U}\boldsymbol{\Sigma}\mathbf{V}^T \tag{7}$$

Onde as colunas de $\mathbf{V} \in \mathbb{R}^{d \times d}$ representam as direções dos Componentes Principais. A projeção bidimensional nos dois primeiros componentes $(\mathrm{PC}_1, \mathrm{PC}_2)$ é obtida por $\mathbf{Z} = \bar{\mathbf{Y}}\mathbf{V}_{:,1:2} \in \mathbb{R}^{N_v \times 2}$.

A reta de ajuste $y = mx + c$ no plano $(\mathrm{PC}_1, \mathrm{PC}_2)$ é encontrada resolvendo os mínimos quadrados. Essa reta de ajuste que melhor representa os dados das duas componentes principais é considerada como a seção de Poincaré.

7.3 Função `get_poincare_intersections(embedded_space)`

- **Motivo da Existência**: Transforma a trajetória contínua do espaço de fase em uma sequência temporal discreta de pontos, reduzindo a dimensionalidade do sinal.
- **Formulação Matemática**: Para cada ponto k, calcula-se a distância orientada até a reta ajustada:

$$f_k = \mathrm{PC}_{2,k} - (m \cdot \mathrm{PC}_{1,k} + c) \tag{8}$$

Ocorre um cruzamento entre o ponto k e $k+1$ se $f_k \cdot f_{k+1} < 0$. O valor exato da coordenada PC_1 no ponto de interseção é estimado por interpolação linear:

$$x_I = \mathrm{PC}_{1,k} + \frac{|f_k|}{|f_k| + |f_{k+1}|} (\mathrm{PC}_{1,k+1} - \mathrm{PC}_{1,k}) \tag{9}$$

7.4 Função `extract_features(intersections)`

- **Motivo da Existência**: Sintetiza o conjunto discreto de interseções de Poincaré $X_I = \{x_{I,1}, x_{I,2}, \ldots, x_{I,M}\}$ em um vetor estático de 7 características estatísticas e não-lineares, adequadas para os modelos de classificação.
- **Formulação Matemática das 7 Características**:

1. **Amplitude/Amplitude Total (Range)**:

$$R = \max(X_I) - \min(X_I) \tag{10}$$

2. **Quantil 0,13 ($Q_{0.13}$)**: Percentil de 13% da distribuição das interseções.
3. **Amplitude Interquartil (IQR)**:

$$\mathrm{IQR} = Q_{0.75}(X_I) - Q_{0.25}(X_I) \tag{11}$$

4. **Entropia de Shannon (baseada em Histograma)**: Estimando a densidade de probabilidade $p(b_j)$ em B compartimentos (bins escolhidos pela regra de Sturges, $B = \lceil \log_2 M \rceil + 1$):

$$H = -\sum_{j=1}^{B} p(b_j) \log_2 p(b_j), \quad \text{para } p(b_j) > 0 \tag{12}$$

5. **Valor Quadrático Médio (RMS)**:

$$\mathrm{RMS} = \sqrt{\frac{1}{M} \sum_{i=1}^{M} x_{I,i}^2} \tag{13}$$

6. **Coeficiente de Variação (CV)**:

$$\mathrm{CV} = \frac{\sigma(X_I)}{\mu(X_I)} = \frac{\sqrt{\frac{1}{M}\sum (x_{I,i} - \bar{x})^2}}{\bar{x}} \tag{14}$$

7. **Energia Interna (E)**:

$$E = \sum_{i=1}^{M} x_{I,i}^2 \tag{15}$$

7.5 Funções `extract_all_poincare_features` e `process_single_file`

- **Motivo da Existência**: Aplica o processo de extração para todos os 23 canais eletroencefálicos montados no sistema 10-20, gerando um vetor consolidado por janela de tempo de dimensão $23 \times 7 = 161$ características.
- **Estratégia de Processamento**: Segmenta trechos com crises epilépticas anotadas (label = 1) em janelas de 1 segundo sem sobreposição, e amostra aleatoriamente janelas de fundo sem crise (label = 0) para balanceamento local de dados.

8 Etapa 3: Treinamento e Validação do Classificador (`svm_training.py`)

8.1 Classe `LinearSVM(nn.Module)`

- **Motivo da Existência**: Implementa um classificador SVM com kernel linear como um módulo customizado em PyTorch, operando a fronteira hiperplana $w^T x + b$.
- **Equação da Fronteira de Decisão**:

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b \tag{16}$$

8.2 Funções `fit_scaler(X)` e `apply_scaler(X, mean, std)`

- **Motivo da Existência**: O SVM é sensível à escala dos atributos devido ao termo de regularização da norma $\|w\|^2$. O escalonamento Z-score padroniza cada atributo para ter média zero e desvio padrão unitário. [isso é pré-processamento sugerido pelo scikit learn]
- **Formulação Matemática**:

$$\mu_j = \frac{1}{N} \sum_{i=1}^{N} X_{i,j}, \quad \sigma_j = \sqrt{\frac{1}{N} \sum_{i=1}^{N} (X_{i,j} - \mu_j)^2} \tag{17}$$

$$\hat{X}_{i,j} = \frac{X_{i,j} - \mu_j}{\sigma_j + \epsilon} \tag{18}$$

8.3 Função `train_linear_svm(X, y, C, epochs, lr, ...)`

- **Motivo da Existência**: Otimiza os pesos $\mathbf{w}$ e bias b do modelo minimizando a função de perda de margem suave (*soft-margin hinge loss*) via otimizador Adam em ambiente GPU/CPU.
- **Formulação Matemática do Objetivo Primal**: Considerando rótulos transformados $y_i \in \{-1, +1\}$ e pesos de classe w_i, a função de custo total $L(\mathbf{w}, b)$ otimizada é:

$$\min_{\mathbf{w},b} \left[\frac{1}{2} \|\mathbf{w}\|^2 + C \cdot \frac{1}{N} \sum_{i=1}^{N} w_i \cdot \max\left(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)\right) \right] \tag{19}$$

Onde C é a constante de regularização que equilibra a largura da margem e o erro de classificação.

8.4 Função `compute_metrics(y_true, y_pred)`

- **Motivo da Existência**: Avalia clinicamente o desempenho do modelo no diagnóstico do padrão ictal usando a matriz de confusão: Verdadeiros Positivos (TP), Verdadeiros Negativos (TN), Falsos Positivos (FP) e Falsos Negativos (FN).
- **Métricas**:

$$\text{Acurácia (Acc)} = \frac{TP + TN}{TP + TN + FP + FN} \tag{20}$$

$$\text{Sensibilidade (Recall)} = \frac{TP}{TP + FN} \tag{21}$$

$$\text{Especificidade (Spe)} = \frac{TN}{TN + FP} \tag{22}$$

8.5 Função `train_patient_specific_models(...)`

- **Motivo da Existência**: Executa o fluxo de treinamento individualizado por paciente.
- **Estratégia de Validação**:
    1. Divisão Cronológica: Os primeiros 50% das janelas ordenadas no tempo são destinados ao treino, e os 50% restantes ao teste.
    2. Otimização de Hiperparâmetros: Realiza validação cruzada estratificada em K pastas (*Stratified K-Fold CV*) sobre o conjunto de treino para definir a melhor constante $C \in \{0.001, 0.01, 0.1, 1, 10, 100\}$.
    3. Re-treinamento e Teste: Re-treina o modelo com o melhor C selecionado sobre todo o conjunto de treino e realiza a predição cega no conjunto de teste futuro.

9 Resultados

TODO

10 Conclusão

TODO

Preencher as referências com os novos artigos que eu salvei. Colocar os sites de documentação do scikit learn e pytorch

Referências

[1] Hospital Israelita Albert Einstein. Epilepsia - glossário de saúde. URL: https://www.einstein.br/n/glossario-de-saude/epilepsia.

[2] World Health Organization. Epilepsy fact sheet. URL: https://www.who.int/news-room/fact-sheets/detail/epilepsy.

[3] PMC. Therapeutic efficacy of voltage-gated sodium channel inhibitors in epilepsy. *PubMed Central*, 2024. URL: https://pmc.ncbi.nlm.nih.gov/articles/PMC11960332/.

[4] Associação Brasileira de Epilepsia. O que é sudep? URL: https://epilepsiabrasil.org.br/sudep/.

[5] Alta Diagnósticos. Eletroencefalograma (eeg): O que é, para que serve e como é feito. URL: https://altadiagnosticos.com.br/saude/eletroencefalograma/.

[6] Ali Shoeb. Chb-mit scalp eeg database, 2009. URL: https://physionet.org/content/chbmit/1.0.0/.

[7] Ali Hossam Shoeb. *Application of machine learning to epileptic seizure onset detection and treatment*. PhD thesis, Massachusetts Institute of Technology, 2009.

[8] Matthias Ihle, Hinnerk Feldwisch-Drentrup, César A Teixeira, Adrien Witon, Björn Schelter, Jens Timmer, and Andreas Schulze-Bonhage. Epilepsiae–a european epilepsy database. *Computer methods and programs in biomedicine*, 106(3):127–138, 2012.

[9] Freiburg Seizure Prediction Project. Publications and eeg database. URL: https://www.epilepsy.uni-freiburg.de/freiburg-seizure-prediction-project/publications.

[10] J Pavei, R Walz, and JLB Marques. Estudo de biomarcadores para predição de crises epilépticas utilizando ecg.

[11] Universidade Federal de São João Del-Rei. Pesquisa sobre controle de epilepsia é premiada em congresso nacional. URL: https://ufsj.edu.br/noticias_ler.php?codigo_noticia=7245.

[12] Raja Mourad, Ahmad Diab, Zaher Merhi, Mohamad Khalil, and Régine Le Bouquin Jeannès. A lightweight autoencoder model for epileptic seizure detection. In *2025 33rd European Signal Processing Conference (EUSIPCO)*, pages 1512–1516. IEEE, 2025.

[13] Saarang Panchavati, Samuel Vander Dussen, Hemal Semwal, Ahmed Ali, Justin Chen, Haoran Li, Corey Arnold, and William Speier. Pretrained transformers for seizure detection. In *ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 1–2. IEEE, 2023.

[14] Yonglin Wu, Jionghui Liu, Yangyang Yuan, Haoran Ren, Chenyun Dai, and Yao Guo. Enhancing epileptic seizure detection with random input selection in graph-wave networks. In *2024 46th Annual international conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pages 1–4. IEEE, 2024.

[15] Una Europa. Una europa epilepsy data challenge. URL: https://www.una-europa.eu/calendar/una-europa-epilepsy-data-challenge.

[16] Miguel Bhagubai, Christos Chatzichristos, Lauren Swinnen, Jaiver Macea, Jingwei Zhang, Lieven Lagae, Katrien Jansen, Andreas Schulze-Bonhage, Francisco Sales, Benno Mahler, et al. Seizeit2: Wearable dataset of patients with focal epilepsy. *Scientific Data*, 12(1):1228, 2025.

[17] J Prasanna, MSP Subathra, Mazin Abed Mohammed, Robertas Damaševičius, Nanjappan Jothiraj Sairamya, and S Thomas George. Automated epileptic seizure detection in pediatric subjects of chb-mit eeg database—a survey. *Journal of Personalized Medicine*, 11(10):1028, 2021.

[18] Morteza Zabihi, Serkan Kiranyaz, Ali Bahrami Rad, Aggelos K Katsaggelos, Moncef Gabbouj, and Turker Ince. Analysis of high-dimensional phase space via poincaré section for patient-specific seizure detection. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 24(3):386–398, 2015.

[19] A. Van Esbroeck, L. Smith, Z. Syed, S. Singh, and Z. N. Karam. Multi-task seizure detection: Addressing intra-patient variation in seizure morphologies. *Machine Learning*, 102:309–321, 2016.

[20] F. Alickovic, J. Kevric, and A. Subasi. Performance evaluation of empirical mode decomposition, discrete wavelet transform, and wavelet packed decomposition for automated epileptic seizure detection and prediction. *Biomedical Signal Processing and Control*, 39:94–102, 2018.

[21] L. Murali, D. Chitra, T. Manigandan, and B. Sharanya. An efficient adaptive filter architecture for improving the seizure detection in eeg signal. *Circuits, Systems, and Signal Processing*, 35:2914–2931, 2016.